


Pipeline de Datos en la Nube

Caso DataCo · Arquitectura de datos para distribución de consumo masivo

JUAN PABLO GALLEGO VALENCIA

YEFERSON GRAJALES

FREDY ALBERTO LICONA MENA



Made with GAMMA

¿Qué es DataCo?

12

Departamentos

Cobertura nacional

9K+

Puntos de venta

Supermercados, tiendas, droguerías

1.800

Empleados

Operación activa

320

Vehículos

Flota de distribución

Tres líneas de negocio: **alimentos perecederos, productos de aseo y cosméticos y cuidado personal.**



Arquitectura Actual: Sistemas Fragmentados

SAP ON-PREMISE
ERP DE VENTAS
Y FACTURACIÓN



ORACLE DATABASE
INVENTARIO
Y STOCK



ARCHIVOS CSV
GPS DE FLOTA,
RUTAS



SALESFORCE
CRM COMERCIAL,
CLIENTES



El problema central

Cuatro sistemas operan de forma **aislada**, sin integración automática.

- SAP On-Premise → facturación
- Oracle → inventario
- CSV → rutas GPS
- Salesforce → CRM

⚠ Sin orquestación: consolidación 100% manual en Excel.



Impacto Operativo

 **3–5 días**

Para generar reportes ejecutivos

 **72 horas**

De retraso en datos de inventario

 **Sin trazabilidad**

Sin correlación entre facturas, entregas y rutas

 **Escalabilidad crítica**

Reportes tardan hasta 8 horas en temporada alta

Drivers de la Solución

Drivers Funcionales

→ Automatización

Eliminar procesos manuales en Excel

→ Modelo consolidado

Unificar ventas, inventario, logística y CRM

→ Dashboards ejecutivos

Visualización en Power BI

Drivers No Funcionales

→ Escalabilidad

Hasta 5 millones de registros por ejecución

→ Disponibilidad

Datos con máximo 4 horas de rezago


→ Costo

No superar USD 80 mensuales en piloto

ASR — Requerimientos Arquitectónicamente Significativos

Código	Requerimiento	Prioridad	Impacto
ASR-01	Integrar 4 sistemas fuente	● Alta	Elimina fragmentación
ASR-02	Actualizar datos cada 4h máx.	● Alta	Reduce decisiones tardías
ASR-03	>98% registros limpios	● Alta	Confiabilidad en reportes
ASR-06	Costo < USD 80/mes	● Alta	Condiciona selección Azure
ASR-07	Proteger información sensible	● Alta	Control de acceso por roles

Modelo C4 — Nivel C1: Contexto del Sistema




Ecosistema de datos

La plataforma centraliza cuatro fuentes heterogéneas y entrega datos limpios a tres actores de negocio.

- **Analista BI** → reportes técnicos
- **Gerente Comercial** → decisiones estratégicas
- **Auditor** → gobierno de datos

Arquitectura de Contenedores — Nivel C2



Pipeline orquestado con **Azure Data Factory**, procesado en **Databricks** y almacenado en **ADLS Gen2 + Azure SQL**. Actualización cada 4 horas.

Decisiones Arquitectónicas (ADRs)

1

Orquestación

Azure Data Factory — conectores nativos, reintentos automáticos

2

Transformación

Databricks Community — Python/Spark, costo cero

3

Data Lake

ADLS Gen2 + Parquet — compresión y velocidad analítica

4

Almacén Analítico

Azure SQL Database — tier gratuito 32 GB, integración Power BI

5

Visualización

Power BI Desktop — licencia existente, costo adicional cero



Resultados Esperados del Piloto

⚡ Automatización

De 3–5 días a **4 horas** de actualización

✓ Calidad

Más del **98%** de registros limpios

💰 Costo

Piloto bajo **USD 80/mes** con Free Tier

🔗 Trazabilidad

Correlación automática: facturas → rutas → entregas